FACULTAD DE
ESTUDIOS ESTADÍSTICOS
UNIVERSIDAD COMPLUTENSE DE MADRID

Calidad de Sueño

Estudio completo a partir de datos reales estimando la calidad de sueño esperada de los individuos a partir de factores individuales como hábitos de vida, salud e indicadores de estrés a través de diversos tipos de modelos

Patricia Fernández Sanz

ÍNDICE

1. INTRODUCCIÓN pág. 3

1.1. ANÁLISIS DESCRIPTIVO BÁSICO pág. 3

1.2. DEPURACIÓN DE DATOS pág. 4

1.3. ENTRENAMIENTO PRUEBA pág. 5

2. MODELO GLM pág. 5

2.1. MODELO ORDINAL pág. 5

2.2. MODELO MULTINOMIAL pág. 8

2.3. PROPORCIONALIDAD pág. 9

3. ÁRBOLES pág. 10

3.1. ÁRBOL ORDINAL pág. 10

3.2. EVALUACIÓN DEL ÁRBOL GANADOR pág. 12

4. RANDOM FOREST pág. 12

4.1. CREACIÓN DE RANDOM FOREST pág. 13

4.2. EVALUACIÓN DE RANDOM FOREST pág. 14

5. GRADIENT BOOSTING pág. 14

5.1. GRADIENT BOOSTING PARA CLASIFICACIÓN pág. 15

5.2. EVALUACIÓN DE GRADIENT BOOSTING pág. 16

6. COMPARACIÓN DE TODOS LOS MODELOS pág. 17

7. CONCLUSIONES pág. 18

8. ANEXO pág. 20

1. INTRODUCCIÓN

En el siguiente trabajo se aplican distintas técnicas de modelización predictiva con el fin de, a partir de datos de individuos reales, predecir y estimar la calidad de sueño esperada a partir de factores individuales como hábitos de vida, salud e indicadores de estrés.

Para ello, la base de datos cuenta con 774 sujetos donde se reflejan sus consumiciones de café y alcohol, hora a la que suelen despertarse e irse a la cama, frecuencia con la que hacen deporte y otros hábitos en un total de 21 variables sin contar con la variable objetivo "calidad de sueño".

Antes de proceder con cualquier proceso, se debe hacer un análisis y depuración de los datos.

1.1. ANÁLISIS DESCRIPTIVO BÁSICO

Como se ha mencionado anteriormente, la base cuenta con 774 observaciones y 22 variables. Cada observación representa a un individuo. Las variables son las siguientes

- **Age**: Edad del individuo
- **Gender**: Sexo del individuo
- **Occupation**: Profesión del individuo
- **Marital_Status**: Soltero, Casado o Divorciado
- **Sleep_Duration**: Número de horas que ha dormido
- **Sleep_Quality**: Calidad de sueño entre 1 y 5 que siente que ha experimentado el individuo
- **Wake_Up_Time**: Hora a la que se despierta normalmente
- **Bed_Time**: Hora a la que se acuesta normalmente
- **Physical_Activity**: Frecuencia con la que hace deporte a la semana
- **Screen_Time**: Horas diarias de uso de pantallas en media del individuo
- **Caffeine_Intake**: Cantidad de cafeína consumida (tazas de café) diaria
- **Alcohol_Intake**: Cantidad de bebidas alcohólicas consumidas (bebidas por semana)
- **Smoking_Habit**: Si fuma o no
- **Work_Hours**: Número de horas trabajadas
- **Travel_Time**: Número de horas al día invertidas en transporte
- **Social_Interactions**: Frecuencia de interacciones sociales (eventos sociales) en media semanales
- **Meditation_Practice**: Si el individuo medita o no
- **Exercise_Type**: Tipo de ejercicio deportivo que hace
- **Blood_Pressure**: Niveles de presión en sangre
- **Cholesterol_Level**: Nivel de colesterol (mg/dL).
- **Blood_Sugar_Level**: Nivel de azúcar en sangre (mg/dL).
- **Stress_Detection**: Nivel de estrés (Low, Medium o High

Para el estudio, se utiliza **Sleep_Quality** como variable objetivo.

1.2. DEPURACIÓN DE DATOS

Antes de comenzar a desarrollar los modelos, era necesario revisar las distintas variables, analizar los valores que toman cada una de ellas y su distribución. Este proceso incluyó la transformación de variables a formato factor, recodificación de algunas de ellas para facilitar su análisis y reagrupación de categorías con baja frecuencia de observaciones.

En primer lugar, se transformaron a variables de tipo factor **Gender, Occupation, Marital_Status, Smoking_Habit, Meditation_Practice, Exercise_Type y Stress_Detection**. Así mismo, las variables **Wake_Up_Time y Bed_Time** que originalmente estaban en formato date() fueron recodificadas para que tomaran valores numéricos en formato horario.

En el caso de **Bed_Time**, se tuvo en cuenta que algunos individuos indicaron horas posteriores a la medianoche (por ejemplo, 1:00 AM o 2:00AM), que podrían interpretarse erróneamente como horas tempranas cuando en realidad corresponden al final del día. Para evitar este problema, se estableció un horario continuo, extendiendo las horas más allá de las 23:00. De este modo, las 00:00 pasaron a representarse como 24, la 1:00 como 25, y así sucesivamente.

Respecto a la reagrupación de categorías, la variable objetivo **Sleep_Quality** toma valores numéricos con decimales en función de la calidad de sueño percibida por el individuo. A pesar de que la variable puede tomar valores desde 1 hasta 5, los individuos han valorado su calidad de sueño entre 2 y 5 con valoraciones intermedias como 2,9 o 3,7.
Además, algunas puntuaciones contaban con un porcentaje elevado de individuos, como es el caso de la puntuación 4, que representaba aproximadamente el 27%, mientras que otros valores intermedios (por ejemplo, 2.5 o 2.9) apenas contaban con dos o tres observaciones.
Para evitar problemas derivados de las bajas frecuencias y mejorar la interpretabilidad, se agruparon los valores en cuatro categorías ordinales (Pobre, de 2 a 3.4, Aceptable de 3.5 a 3.8, Buena de 3.9 a 4 y Excelente de 4.1 a 5).
Con esta partición, se obtiene una variable más equilibrada, pues todas tienen en torno al 21-23% de los individuos a excepción de Buena que cuenta con el 34%.

Las variables **Occupation** y **Exercise_Type** contaban con muchas categorías y la gran mayoría con pocos individuos por lo que, se reagruparon para hacerlas más útiles.
La primera presentaba 169 categorías distintas que se agruparon en 4 grandes (Ciencia, Creativo y Práctico, Económico y Público) que representaban el 21%, 35%, 16% y 27% de los individuos aproximadamente cada una de ellas. De esta manera, se cuenta con 4 categorías relativamente balanceadas a 169 donde prácticamente cada 4 individuos encontramos una profesión distinta.

En la segunda, algunas categorías como Walking, Meditation o Aerobics contaban con escasa representación, por lo que se generaron tres nuevas categorías más amplias, Cardio, Cuerpo y Mente y Fuerza que cuentan con el 29%, 32% y 39% respectivamente.
Una vez realizadas todas estas transformaciones y recodificaciones se comprobó que ninguna variable contaba con datos ausentes ni atípicos relevantes para el análisis.

1.3. ENTRENAMIENTO PRUEBA

Previo a la construcción de los modelos, se realiza una división entrenamiento-prueba para poder así contar con un subconjunto de datos diferente para evaluar los modelos más adelante.
Se asigna el 80% de los datos a entrenamiento y el 20% restante a prueba, manteniendo las proporciones de cada categoría de la variable objetivo en cada subconjunto.
A tener en cuenta que, debido a la naturaleza de algunos modelos, estas particiones se realizan nuevamente más adelante tras realizar recodificaciones, pero en la mayoría de los casos se mantiene la proporción 20% para pruebas y 80% para entrenamiento.

2. MODELO GLM

Como se ha explicado en apartados anteriores, la variable objetivo **Sleep_Quality** ha sido recodificada en cuatro categorías ordinales y, por tanto, se trata de una variable categórica ordinal, es decir, existe un orden natural entre sus niveles, aunque la distancia entre ellos no es necesariamente constante.
Debido a esta característica, para seleccionar el mejor modelo dentro de los GLM se han considerado dos enfoques: regresión ordinal y regresión multinomial.

2.1. MODELO ORDINAL

La regresión ordinal aprovecha el orden de la variable, es más eficiente estadísticamente y requiere menos parámetros que la regresión multinomial.
Antes de comenzar con el ajuste del modelo, se comprobó que los niveles de la variable **Sleep_Quality** estuvieran correctamente ordenados según su significado (de Pobre a Excelente) y que los nombres de las categorías no presentaran caracteres problemáticos (tildes, espacios, símbolos, etc.) que pudieran generar errores en las funciones utilizadas. En este caso, la variable ya se encontraba correctamente codificada, por lo que no fue necesaria ninguna modificación adicional.

Se ajustó un primer modelo inicial el cual incluía todas las variables independientes y contaba con un total de 29 parámetros.

La salida del modelo proporcionada con summary() mostraba los coeficientes estimados, sus errores estándar y los valores t asociados. Dado el tamaño muestral relativamente grande, se tomó como valor de referencia |1.96| para determinar la significatividad al 95%.
Bajo este criterio, 10 parámetros resultaron estadísticamente significativos. Además, este primer modelo contaba con un AIC de 1511.384
Con el objetivo de estudiar la contribución individual de cada variable, se realizó un análisis de tipo II donde se identificaron como significativas al 5% las variables **Social_Interactions, Work_Hours, Alcohol_Intake, Wake_Up_Time, Travel_Time, Caffeine_Intake, Gender y Sleep_Duration**

A partir del análisis anterior se ajustó un segundo modelo utilizando únicamente las 6 variables aparentemente más importantes (las seis primeras de las mencionadas arriba). Este nuevo modelo indicaba que ahora todos los parámetros sí que eran significativos pero, el valor AIC es mayor al del modelo con todo (puesto que pasa de 1511 a 1527).
Para verificar si se están prescindiendo de variables necesarias se hizo uso de la función add1(). Se verificó que varias variables aportarían información relevante al modelo como Gender o Blood_Preassure y no habían sido incluidas.

Dado que el modelo construido manualmente sería demasiado sencillo y el que cuenta con todas las variables demasiado sobre ajustado, se obtuvieron otra serie de modelos aplicando métodos automáticos de selección de variables. Para ello se deben construir dos modelos iniciales, uno máximo y otro mínimo y se aplicarán los 3 métodos de selección de variables (Forward, Backward y Stepwise) y los 2 criterios de selección (AIC y BIC).
Los 6 procesos dan como resultado a 4 modelos distintos, con 10, 11 y 17 parámetros respectivamente.
El modelo de 10 parámetros y el de 11 son iguales, salvo que el último contiene además la variable **Sleep_duration** y los de 17 parámetros añaden además **Gender, Bed_Time, Smoking_Habit, Marital_Status** y uno de ellos añade **Screen_Time** mientras que el otro hace uso de **Physical Activity**.

Para poder determinar cuál de los modelos es mejor, se va a recurrir a la validación cruzada repetida, gracias a la cual se podrán evaluar los modelos mediante las medidas ya estudiadas.
Se estudia la capacidad predictiva, variabilidad y número de parámetros de los modelos (ver *Figura 1*).
La capacidad predictiva se evalúa observando la mediana. Queremos la mediana más alta para un mejor rendimiento. Observamos como los modelos de 10 y 11 parámetros muestran medianas ligeramente superiores en Kappa, Wkappa y Accuracy.

La variabilidad se mide por la dispersión de los resultados. Un modelo será más estable cuanto más estrechos sean su caja y bigotes. Todos los modelos muestran una variabilidad similar pero en general los modelos de más parámetros parecen tener cajas más estrechas, lo que sugiere mayor estabilidad.

Finalmente, el principio de parsimonia sugiere elegir el modelo más simple (con menor número de parámetros) que explique tan bien los datos como un modelo más complejo.

Realizado el estudio, y buscando el mejor equilibrio entre capacidad predictiva, variabilidad y número de parámetros, el modelo más prometedor es el Model3_10, es decir BackBIC, ya que es de los que menos parámetros tiene, su rendimiento es muy similar a los modelos de 17 parámetros aún reduciendo en un 30% su número de parámetros y todos los valores entre los distintos modelos son bastante cercanos, por lo que nos quedamos con el más sencillo.

Seleccionado el mejor modelo, se obtienen los ODDS ratios del mismo y se realiza una evaluación y análisis final mediante los datos de prueba.

Todos los parámetros son significativos.

- **Wake_Up_Time**: Por cada hora adicional en que tarda en despertarse, las posibilidades de tener una percepción de calidad de sueño mayor aumentan en un 37%.
- **Caffeine_Intake**: Por cada taza de café adicional ingerida en el día, las posibilidades de tener una percepción de calidad de sueño mayor aumentan en un 56%.
- **Alcohol_Intake**: Por cada bebida alcohólica adicional que se tome durante la semana, las posibilidades de tener una percepción de calidad de sueño mayor aumentan en un 53%.
- **Work_Hours**: Por cada hora adicional que se trabaje, las posibilidades de tener una percepción de calidad de sueño mayor disminuyen en un 36%.
- **Travel_Time**: Por cada hora adicional que haya que emplear en transporte, las posibilidades de tener una percepción de calidad de sueño mayor disminuyen en un 41%.
- **Social_Interactions**: Por cada interacción social adicional durante la semana, las posibilidades de tener una percepción de calidad de sueño mayor aumentan casi por 3,5.
- **Blood_Sugar_Level**: Finalmente, por cada mg/dL adicional de nivel de azúcar en sangre, las posibilidades de tener una percepción de calidad de sueño mayor aumentan en un 4%.

Para completar el estudio de las variables que componen el modelo, se realiza nuevamente el análisis de tipo II, detectando las variables más importantes, la cual sigue siendo **Social_Interactios** seguida de **Work_Hours**, **Blood_Sugar_Level** y **Travel_Time.**

Finalmente, se obtienen las medidas de evaluación del modelo para el conjunto de prueba. Se observa que en términos generales no parece ser un muy buen modelo, pues cuenta con una tasa de acierto del 44% y un índice kappa del 20%. No obstante, esto son medidas diseñadas para variables multinomiales, ya que asume que todos los errores son igual de graves pero, en la realidad, equivocarse de pronosticar una calidad de sueño de Excelente a Buena no es lo mismo que de Excelente a Pobre.

A pesar de que es capaz de detectar de manera bastante sólida cuando una observación no pertenece a las clases Pobre, Aceptable o Excelente, no se le da especialmente bien clasificar correctamente una observación en ninguna de las clases.

Para ampliar la evaluación, vamos a recurrir al índice Kappa ponderado. Al realizarlo se observa como el valor de kappa ponderado aumenta a 0.3254 respecto al kappa clásico que se queda en 0.2047. Equivocarse en un nivel se considera acertar en dos tercios. Este aumento tiene sentido teniendo en cuenta la matriz de confusión obtenida, el modelo cuenta con una calidad justa.

2.2. MODELO MULTINOMIAL

La regresión multinomial es categórica pero no asume orden, calcula la probabilidad de que cada categoría suceda frente a la de referencia. Es más flexible puesto que permite efectos diferentes para cada categoría pero pierden la información del orden, requiere de más parámetros y su interpretación es más compleja.

Se va a generar un primer modelo multinomial que contenga todas las variables. Este primer modelo cuenta con 81 parámetros ya que el valor que aparece entre paréntesis denominado como variable en realidad nos muestra el número de parámetros. Como el proceso converge, el resultado obtenido es óptimo.

Como se mencionaba y debido a la naturaleza de este tipo de modelos, hablar sobre los valores de los parámetros y cómo afectan a cada categoría de la variable objetivo respecto a la categoría de referencia (Pobre) se hace un proceso costoso y largo.
Para poder comparar con el resultado obtenido a partir de la regresión ordinal se procede a crear los modelos automáticos y seleccionar el mejor de los mismos.
En esta ocasión se obtienen 2 modelos, con 21 y 45 parámetros respectivamente.
Para poder determinar cuál de los modelos es mejor, se va a recurrir a la validación cruzada repetida, gracias a la cual se podrán evaluar los modelos mediante las medidas ya estudiadas (ver *Figura 2*).

Por el principio de parsimonia y a la vista de la falta de diferencia tanto en capacidad predictiva como en variabilidad, optamos por el modelo con menor número de parámetros formulado a través de ForwBIC.
Seleccionado el mejor modelo, se obtienen los ODDS ratios del mismo y se va a realizar una evaluación y análisis final mediante los datos de prueba.

En este caso, se obtiene para cada variable como influye en cada una de las categorías de la variable objetivo **Sleep_Quality** a partir de la categoría de referencia Pobre.
Respecto al Género, se observa cómo ser mujer disminuye las posibilidades de tener una percepción de calidad de sueño Aceptable respecto a Pobre en un 58%, de Buena respecto a Pobre en un 55% y de Excelente respecto a Pobre en un 62%.
Sin embargo, en variables como la presión sanguínea, un incremento unitario en la presión no influye en las posibilidades de una percepción de calidad de sueño Aceptable respecto a Pobre ni Buena respecto a Pobre pero sí aumentan en un 9% de Excelente respecto a Pobre.

Finalmente, se obtienen las medidas de evaluación del modelo para el conjunto de datos de prueba. Comparando los resultados de este modelo respecto a los obtenidos con el modelo de regresión ordinal, las métricas de tasa de acierto e índice kappa han aumentado en 7 puntos porcentuales respectivamente pero, respecto a sensibilidad y especificidad todas las métricas se han acercado más a 0.5, por lo que el modelo no es especialmente bueno clasificando las observaciones.

2.3. PROPORCIONALIDAD

A la vista de que el modelo multinomial no ha mejorado significativamente al ordinal, vamos a obtener un nuevo modelo multinomial con las mismas variables que el modelo ordinal ganador y evaluar si ahí sí que existe una mejora significativa.

Al evaluar este nuevo modelo sobre el conjunto de prueba y comparar los resultados vemos que la tasa de acierto y valores kappa.
Sin embargo, al comparar el cambio de manera estadística obteniendo la verosimilitud de ambos modelos y comparándola, se comprueba que a pesar del aumento de 14 parámetros, la mejora en la verosimilitud es significativa.

Por tanto, se concluye que el modelo multinomial con las variables del ordinal es preferible y que la hipótesis de proporcionalidad no se estaba cumpliendo de manera general. Sin embargo, al crear el modelo multinomial por su cuenta eso no se reflejaba muy bien.

En conclusión, vamos a considerar como mejor modelo GLM el modelo multinomial creado anteriormente (ya se encuentra evaluado en la sección anterior).

3. ÁRBOLES

En esta ocasión y de manera análoga a lo que sucedía con los modelos GLM podemos realizar árboles tanto ordinales como de clasificación.

Los árboles ordinales están especialmente diseñados para variables categóricas ordinales. Es importante destacar que aunque es posible construir modelos de clasificación para variables ordinales ignorando la componente ordinal, si el orden de los niveles es importante, como sucede en nuestro caso, es preferible optar por estos pues están diseñados para respetar dicho orden, por lo que sólo se realizarán árboles de este tipo

3.1. ÁRBOL ORDINAL

La función que generan los árboles ordinales precisa que las variables dependientes estén codificadas como numéricas asignando un número según el orden de menor a mayor.
Una vez esté codificada correctamente, se realiza nuevamente la partición entrenamiento prueba.

Para ver una primera modelización, vamos a partir de un árbol con tamaño de hoja mínimo del 5%, indicando que no realice la poda ni obtenga reglas sustitutas.
A partir de este árbol generamos más adelante otros para poder determinar el tamaño mínimo de hoja, parámetro de la poda y número de reglas sustitutas que mejor nos puedan ayudar en un futuro a tomar decisiones.

Se ha construido un árbol con 11 hojas y una profundidad de 6 (ver *Figura 3*), y que el resultado aparece con una gama de colores donde los claros corresponden con los niveles bajos de la variable, es decir calidad de sueño percibida Pobre o Aceptable y los oscuros son los altos, Buena o Excelente.

Cada nodo muestra la categoría predicha y observamos que al menos hay dos nodos para cada categoría.
Aquellos con mejor percepción de calidad de sueño son aquellos que han tenido más de 3 interacción sociales en la semana y han dormido más de 7.3 horas o, habiendo dormido menos de 7 horas, contaban con un nivel de presión en sangre mayor a 138 y habían empleado en transporte más de 4,5h.

Sin embargo, para asegurar el mejor árbol posible, es preferible dejar que crezca siendo más flexibles con el tamaño mínimo de hoja y así poder podarlo. Por ello, construimos un árbol con el 1%. Ahora el árbol es prácticamente imposible de ver ya que es muy grande (ver *Figura 4*).

Este nuevo árbol cuenta con 31 hojas pero permite aumentar el índice kappa ponderado significativamente tanto en entrenamiento como en prueba.
De igual manera, ha aumentado el sobreajuste, por lo que vamos a podar este árbol para procurar conseguir un tamaño de árbol más manejable, con similar capacidad predictiva y, a poder ser, reduciendo el sobreajuste.

Para determinar el tamaño del árbol al realizar la poda, se observa la mejora relativa de cada uno de los árboles podados (ver *Figura 5*).
Se observa que a partir de las 13 hojas el error relativo no disminuye significativamente, por lo que podríamos podar el árbol a ese tamaño.
No obstante y teniendo en cuenta que en árboles se persigue el equilibrio entre la interpretabilidad y capacidad predictiva, un tamaño de 9 también podría ser razonable.
Respecto al sobreajuste, se observa que este es menor en 9 hojas respecto a 13.
De igual manera, también graficamos el número de hojas del árbol en función del kappa ponderado (ver *Figura 6*) y, de igual manera, se confirma que un árbol de 9 hojas parece ser lo suficientemente bueno pues la mejora respecto a un árbol de 15 hojas no es tan notoria y, un árbol más grande será más complejo de interpretar.

Se realiza por tanto la poda y observamos un árbol de 9 hojas y profundidad de 5, con hojas de distinta tonalidades (ver *Figura 7*).
Se observa como 3 de ellas están asociadas a calidad de sueño percibida Excelente, y el resto de categorías tienen 2 hojas asociadas cada una de ellas
Para conocer el grado de credibilidad de las predicciones, creamos una nueva representación gráfica del árbol donde se muestra un gráfico de barras para cada hoja (ver *Figura 8*).

Se observa que las hojas más creíbles son las asociadas a la categoría 1, es decir, calidad de sueño percibida Pobre y las dos más a la derecha asociadas a la categoría 4 Excelente. Esto tiene sentido puesto que, por lo general, aquellas poblaciones en los extremos suelen tener características muy diferenciadoras respecto a categorías centrales.
Aún así, a excepción de la hoja central, todas ellas tienen una categoría de predicción significativamente mayor en porcentaje frente al resto de categorías en la misma hoja bastante notoria, por tanto, la el grado de credibilidad de cada hoja es elevado y, por tanto, la predicción de cada categoría dadas una serie de características es fiable.

Cabe destacar que, en caso de que alguna de las observaciones cuente con datos faltantes, se pueden generar reglas sustitutas y, en caso de no tener información para alguna de las "preguntas" del árbol puede ser útil en vez de directamente asociar la observación con la categoría que mayor porcentaje de observaciones contenga.

En este caso, se han generado hasta 2 reglas sustitutas por división. Por ejemplo, en caso de no contar con un valor para **Social_Interactions** en la primera división se puede asignar la observación al nodo de la izquierda si ha trabajado menos de 7.5h o, en caso de tampoco tener ese valor, contar con un nivel de colesterol inferior a 172.5 y al nodo de la derecha en caso contrario a las condiciones.

3.2. EVALUACIÓN DEL ÁRBOL GANADOR

Finalmente, realizamos una evaluación del modelo generado tanto para el conjunto de entrenamiento como para el de prueba.

Al generar un árbol más grande y posteriormente podarlo, hemos obtenido unas métricas más estables y representativas del rendimiento real del modelo. Esto sucede porque se eliminan hojas que no contienen información tan relevante como para merecer la complejidad que conllevan, lo que ayuda a generalizar mejor. Todas las métricas se ven afectadas, disminuyendo ligeramente de entrenamiento a prueba ya que, en el primer conjunto, se obtiene una tasa de acierto de 0.58 y kappa ponderado de 0.55 que en prueba disminuye a 0.47 y 0.41 respectivamente.

De manera similar a como ocurría con los modelos GLM, todas las categorías cuentan con una especificidad mayor que sensibilidad pero, es especialmente bueno clasificando percepciones de calidad de sueño Pobre, alcanzando una sensibilidad de 0.769.
De las 6 variables que utiliza nuestro modelo, se observa que la que más influencia tiene es **Sleep_Duration** con casi el 35%, seguida de **Blood_Preassure** y **Social_Interactions** cercanas al 25% (ver *Figura 9*).

4. RANDOM FOREST

A continuación, vamos a generar un modelo RF, donde se introduce cierta aleatoriedad a la hora de generar los árboles para que entre ellos haya menor correlación y, por tanto, una mejora de la capacidad predictiva.
Debido a la naturaleza de nuestra variable objetivo, haremos uso de bosques aleatorios para clasificación donde nos centraremos en predecir si los individuos pertenecen a una categoría u otra.

En este caso, nos tenemos que asegurar de que la variable es de tipo factor. Como en el apartado anterior la hemos codificado como numérica que toma valores 1,2,3 y 4 basta con pasarla nuevamente a factor y, nuevamente, hacer la división entrenamiento-prueba.

4.1. CREACIÓN DE RANDOM FOREST

Comenzamos creando un RF de 500 árboles con un tamaño de hoja equivalente al 5% con ntree y mtry por defecto, que es equivalente a la raíz cuadrada del número de variables explicativas disponibles.
El modelo da lugar a una tasa de error de 41.77% en las observaciones OOB (out of the bag), es decir, con observaciones que no ha visto o seleccionado para la creación de árboles, una especie de "set de validación".
Es una tasa bastante elevada puesto que es casi la mitad del dataset.
Vamos a ir modificando los distintos parámetros para que tenga mejor capacidad predictiva y elimine lo máximo posible el sobreajuste.

Para determinar el número óptimo de árboles, comparamos el tamaño de dichos árboles con el índice kappa (ver *Figura 10*). Se observa que los mejores modelos se obtienen para unos 300 árboles pero a partir de los 50 el cambio es bastante ligero.

A continuación, vamos a probar a reducir el tamaño de hoja para determinar si esto puede dar lugar a mejores resultados y comparar tanto dicho tamaño como número de árboles necesarios a través de la tasa de fallo e índice kappa de las OOB (ver *Figura 11*).
Disminuir el tamaño de hoja supone una gran mejora en las métricas, existiendo diferencias además entre hojas del 1% y 0.5%, siendo mejor en términos generales la hoja menor.
Así mismo, el mejor valor se alcanza en ambas métricas cuando el número de árboles está alrededor de 150.

El último parámetro que queda por determinar es mtry (número de variables entre las que puede elegir para hacer cada una de las divisiones del árbol). Para ello, nuevamente comparamos los valores mtry frente a la tasa de error e índice kappa (ver *Figura 12*).
Se observa en ambos gráficos de manera clara que el valor óptimo de mtry de 4. Además, se comprueba que esta fuente de aleatoriedad permite resultados mejores respecto al bagging (que sería utilizando las 21 variables predictoras restantes).

Seleccionados los parámetros de 150 árboles, de tamaño mínimo de hoja de 0.05% y valor mtry 4, creamos el modelo RF ganador.

4.2. EVALUACIÓN DE RANDOM FOREST

Con el modelo ganador se observa que efectivamente la tasa de error ha disminuido de casi un 42% a algo menos de un 37%. En términos generales, clasifica mejor las distintas categorías, aunque la que cuenta con una tasa de error mayor es la categoría Excelente (clasifica la mitad de sus observaciones erróneamente).

Obtenemos también una estimación de la calidad en términos de otros indicadores para la partición de prueba y obtenemos AUC de 0.8658 que está bastante bien, una tasa de acierto de 0.634 y un índice kappa ponderado de 0.57. Respecto a las sensibilidades y especificidades siguen en línea a lo obtenido previamente pero funciona ligeramente mejor a como lo hacía el árbol ordinal por sí sólo. Las categorías Pobre y Aceptable cuentan con una sensibilidad superior a 0.7, que no está mal, Buena llega a 0.57 y Excelente tiene una sensibilidad ligeramente inferior a 0.5. Como veníamos indicando, es la categoría a la que más le cuesta asociar observaciones
Aún así, al final del informe se compararán todos los modelos para determinar el mejor o, al menos, el más práctico debido a la naturaleza de los datos.

Respecto a la importancia de variables (ver *Figura 13*) se observa que la más importante sigue siendo **Sleep_Duration** al igual que pasaba en el árbol ordinal ganador pero se ha reducido su importancia a un 15% , el resto de variables, aunque importantes, están muy repartidas en porcentaje entre ellas.
Esto sucede porque la aleatoriedad añadida con mtry en los RF permite que se aproveche más el potencial predictivo de las variables “no dominantes” o menos importantes en modelos anteriores

Para contar con un detalle más amplio sobre las variables, se grafica cómo influyen las variables más importantes a cada categoría (ver *Figura 14*).
Se observa que, respecto a la duración del sueño, aquellos con una percepción Excelente o Buena son los que más horas duermen. Sin embargo, y como es de esperar, aquellos que tienen percepciones Pobres o Buenas apenas duermen más de 6h.

5. GRADIENT BOOSTING

Finalmente el último tipo de modelo que vamos a realizar es Gradient Boosting. Sigue más o menos la temática de los Random Forest pero, en vez de crear un montón de árboles distintos entre ellos, van de manera secuencial capturando nueva información. Esto logra una aproximación iterativa al óptimo de una determinada función, la cual permite evaluar la capacidad predictiva del conjunto.

Para poder realizar este tipo de modelos, es necesario que la variable objetivo esté codificada como 0, 1, 2 y 3 y, además, ser de tipo numérico, por lo que hay que hacer dicha modificación previa y luego se realiza la partición.

5.1. GRADIENT BOOSTING PARA CLASIFICACIÓN

Finalmente, el último tipo de modelo que vamos a realizar es un Gradient Boosting. Este tipo de modelos sigue más o menos la temática de los Random Forest pero, en vez de crear muchos árboles distintos entre ellos e "independientes", va capturando nueva información de manera secuencial intentando siempre mejorar el árbol que creó previamente. Esto logra una aproximación iterativa al óptimo y permite evaluar la capacidad predictiva del conjunto.

De manera análoga a los modelos anteriores, comenzamos creando un GB genérico.
Al utilizar una variable que toma más de dos niveles, en la distribución de los datos indicamos "multinomial" en vez de "bernoulli".
Vamos a realizar 500 árboles con una tasa de aprendizaje de 0.1, tamaño mínimo de hoja del 5%, utilizando el 75% de los datos como entrenamiento y el 25% restante para validación y una profundidad del árbol 3.

Al construir este GBM para clasificación, la partición de validación ha indicado que serían sólo necesarios los 69 primeros y se han utilizado todas las variables. Para ver la evolución de deviance, se grafica en función de las iteraciones (árboles necesarios) tanto para el conjunto de datos de entrenamiento como para el de validación (ver *Figura 15*).
A la vista de los resultados, no solo se observa que a partir de los 69 árboles para el conjunto de validación la deviance no mejora, sino que aumenta de manera casi desproporcionada y se aleja cada vez más de lo que se obtienen para el conjunto de entrenamiento, por lo que hay muchísimo sobreajuste.

A continuación, vamos a construir una rejilla de parámetros a evaluar para poder comparar los distintos modelos modificando su tasa de aprendizaje, profundidad del árbol y tamaño de hoja mínimo.
Vamos a limitar las opciones de cada parámetro a 4 para no alargar mucho los procesos pero podríamos ampliar este número.
La rejilla estará compuesta por una tasa de aprendizaje (0.1, 0.05, 0.01 y 0.005), una profundidad máxima de (3, 5, 7 y 9) y tamaños mínimos de hoja del (5%, 2%, 1% y 0.5%).

Creada la rejilla, creamos un modelo para cada una de las 64 combinaciones, con un conjunto de entrenamiento del 75% y 5000 iteraciones, es decir, 5000 árboles para cada modelo.

El mejor modelo obtenido (menor deviance) es el que cuenta con una profundidad de 3, tasa de aprendizaje de 0.05, 13 observaciones mínimo por hoja y hace uso de 125 (ver *Figura 16*). Otro modelo interesante es uno que cuenta con misma tasa de aprendizaje y profundidad pero aumenta el número mínimo de observaciones a 31 y utiliza 138 árboles aumentando muy ligeramente la deviance (de 0.8845 a 0.888)

A la vista del resto de combinaciones a pesar de que otras opciones también parecen buenas, cuentan o bien con un mayor número de árboles o pocas observaciones mínimas, lo que haría que el árbol fuese más grande y, por consiguiente, más difícil de interpretar.

En este caso, vamos a optar por el segundo modelo mencionado e intentar reducir su complejidad con el número de árboles manteniendo la tasa de aprendizaje (ver *Figura 17*).
A la vista de los resultados obtenidos, parece que con 138 árboles se obtienen los mejores resultados, por redondear, vamos a hacer uso de 130 árboles donde obtendremos más o menos los mismos resultados. No hay ninguna otra solución que permita reducir significativamente el sobreajuste.

Por tanto, nuestro modelo GBM ganador cuenta con 130 árboles, de profundidad máxima 3, mínimo 31 observaciones por hoja y para crearlos se tomaba un valor de tasa de aprendizaje de 0.05.

5.2. EVALUACIÓN DE GRADIENT BOOSTING

Una vez descubierta la parametrización óptima y construido el modelo final utilizando los datos de entrenamiento al completo para mejorar la capacidad predictiva, determinamos su calidad final tanto para entrenamiento como para prueba.

En primer lugar, obtenemos los valores AUC obteniendo un área bajo la curva de 0.94 para el conjunto de entrenamiento y 0.84 para el de prueba. A pesar de existir cierto sobreajuste, no parece ser muy excesivo.
En cuanto a la tasa de acierto e índice kappa para el conjunto de prueba observamos que toma valores 0.71 y 0.608 respectivamente, casi de los mejores resultados que hemos obtenido hasta el momento. Además, el índice kappa mejora el valor del índice clásico llegando a 0.644.

Además, observando tanto la matriz de confusión como los valores para sensibilidad y especificidad de cada una de las clases, ahora todas cuentan con valores superiores a 0.71 (a excepción de la sensibilidad de la categoría Excelente, que se reduce a 0.6, pero sigue siendo mejor que en casos anteriores).

Finalmente, observamos la importancia de las variables (ver *Figura 18*). Al igual que sucedía con los últimos modelos generados, la variable más importante es **Sleep_Duration** con una importancia de casi el 30%, seguida de **Travel_Time** y **Cholesterol_Level.**
En este caso vemos cómo, a excepción de la duración de sueño o el tiempo empleado en transporte, las variables más significativas han cambiado bastante respecto a lo que obteníamos anteriormente, siendo el nivel de colesterol una variable más importante que la edad o interacciones sociales, que tomaban papeles más importantes anteriormente.

6. COMPARACIÓN DE TODOS LOS MODELOS

Obtenidos y evaluados todos los distintos modelos de manera individual, procedemos a hacer una comparación global comparando los distintos modelos ganadores en términos de capacidad predictiva, estabilidad y variables utilizadas.

Para ello y para poder hacer las comparaciones de manera más eficiente, realizamos una Tabla que cuenta, para cada modelo, con el valor Tasa de Acierto, Kappa Ponderado, Número de Parámetros y Variables más importantes tanto para el conjunto de entrenamiento como para el de prueba.

Al comparar todos los modelos con las distintas métricas y teniendo en cuenta otros resultados obtenidos a lo largo del informe (como el valor AUC y las métricas de sensibilidad y especificidad en cada uno de los modelos para cada una de las métricas), para clasificar la percepción de calidad de sueño la mejor opción es utilizando el modelo Gradient Boosting.

El GBM cuenta con la mejor capacidad predictiva para el conjunto de datos de prueba, una tasa de acierto del 71% y un kappa ponderado de casi el 65%. Además, muestra gran estabilidad ya que la diferencia de sus métricas entre el conjunto de entrenamiento y el de prueba es muy pequeño, lo que sugiere además que tiene una alta capacidad de generalización ante nuevos datos.
En contraste, el modelo Random Forest, a pesar de que tiene un rendimiento casi perfecto, cuenta con mucho sobreajuste.
Respecto al modelo GLM multinomial y el árbol de decisión ordinal, vemos cómo a pesar de que no están sobre ajustados, tienen un rendimiento general bajo.

Por tanto, el mejor modelo para nuestra base de datos y posibles datos futuros a añadir es el modelo Gradient Boosting ya que cuenta con un equilibrio muy superior respecto a los otros modelos tanto en rendimiento predictivo como en estabilidad.

Modelo	Conjunto	Tasa de Acierto	Kappa Ponderado	Variables utilizadas	Variables más importantes
GLM (mult)	Entrenamiento	0.4483	0.3592	7 (21 parámetros)	Social_Interactions Travel_Time Work_Hours
GLM (mult)	Prueba	0.4379	0.3275	7 (21 parámetros)	Social_Interactions Travel_Time Work_Hours
Árbol	Entrenamiento	0.5848	0.5502	6	Sleep_Duration Blood_Preassure Social_Interactions
Árbol	Prueba	0.474	0.4109	6	Sleep_Duration Blood_Preassure Social_Interactions
RF	Entrenamiento	0.971	0.9709	21 (todas)	Sleep_Duration Age Travel_Time
RF	Prueba	0.6339	0.5752	21 (todas)	Sleep_Duration Age Travel_Time
GB	Entrenamiento	0.7576	0.7323	21 (todas)	Sleep_Duration Travel_Time Cholesterol_Level
GB	Prueba	0.7123	0.6438	21 (todas)	Sleep_Duration Travel_Time Cholesterol_Level

7. CONCLUSIONES

Realizado todo el estudio y a la vista de que el mejor modelo es el obtenido mediante Gradient Boosting, observamos que lo que más determina la calidad de sueño percibida de una persona es la duración de horas dormidas, las horas invertidas en transporte y los niveles de colesterol.

La duración del sueño tiene una importancia de casi el 30% en el modelo GB, lo que subraya una relación directa y muy influyente en la percepción de calidad de sueño.

La inclusión del colesterol en el modelo más preciso en vez de variables como la edad o las interacciones sociales (que fueron más importantes en modelos menos precisos) nos lleva a pensar que hay una interacción compleja subyacente entre la salud metabólica y el sueño.

Debemos recordar que este estudio no mide como tal la calidad de sueño de un individuo, sino la percepción que tiene dicho individuo. Esto es clave para entender bien los resultados obtenidos.

La duración del sueño confirma la relación primaria entre cantidad y percepción de calidad. Sin embargo, el tiempo de viaje también se suele encontrar muy relacionado con el estrés crónico y la reducción del tiempo de descanso efectivo, mientras que el nivel de colesterol actúa como un marcador biológico que podría incluir sugerir posibles trastornos como la apnea del sueño, lo que podría afectar a la calidad percibida.

La baja influencia de factores como la ingesta de café, el género o la edad nos lleva a entender que, por ejemplo, el impacto de la cafeína se ve enmascarado por la autoadaptación de los individuos o su influencia se absorbe a través de otras variables como el estrés.

En este sentido, el estudio cuenta con una utilidad práctica inmediata para la salud pública. Los resultados no sólo permiten enfocar las intervenciones en las horas de sueño, sino también en factores logísticos y de salud metabólica, lo que puede llevar a la concienciación de bienestar de los individuos. Una mala calidad de sueño no se basa sólo en las horas dormidas sino en indicadores como el colesterol o tiempo invertido en el desplazamiento que pueden afectar a la percepción de descanso.

En conclusión, el GBM se establece como la herramienta predictiva más robusta y fiable, tanto por ser estable y contar con una predicción precisa, como por ser capaz de encontrar interacciones complejas entre la logística diaria y la salud metabólica como elementos clave en la percepción subjetiva de la calidad de sueño.

8. ANEXO

Figura 1 (estadísticos para la comparación de los modelos GLM ordinales)

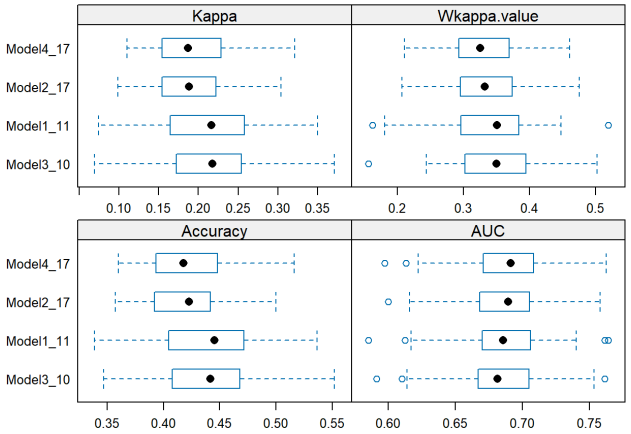

Figura 2 (estadísticos para la comparación de los modelos GLM multinomiales)

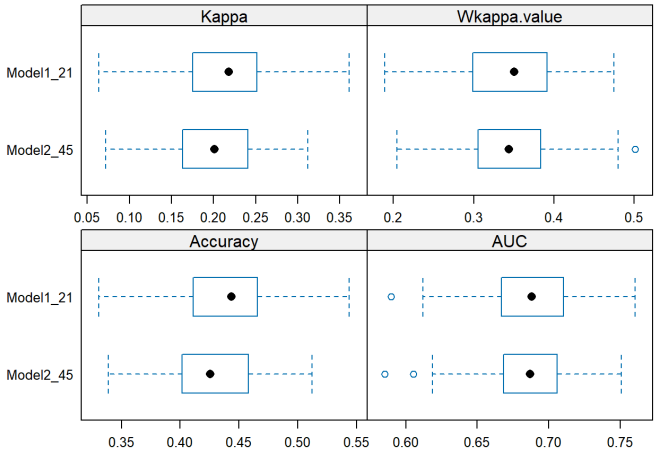

Figura 3 (árbol ordinal inicial con tamaño de hoja al 5%)

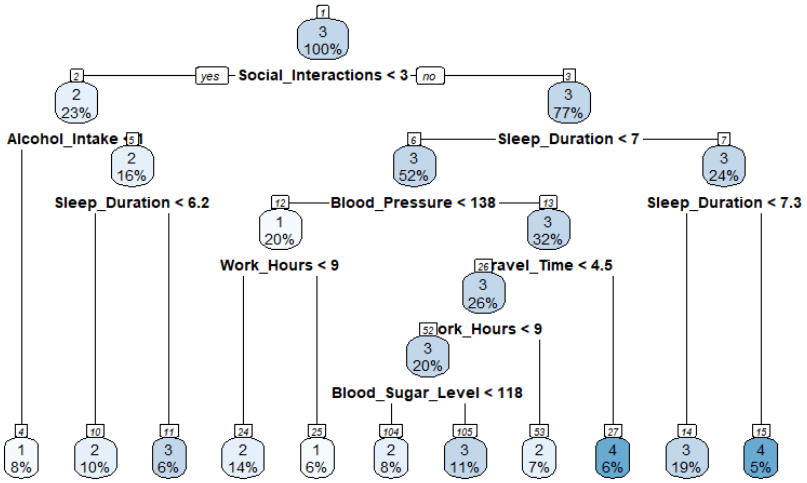

Figura 4 (árbol ordinal con tamaño de hoja 1% para podar)

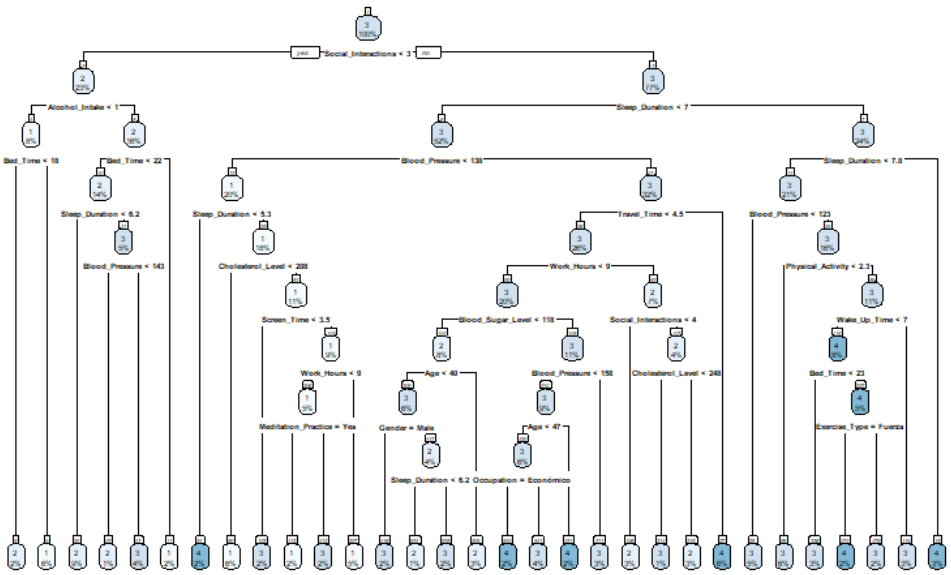

Figura 5 (tamaño del árbol frente a la mejora del error relativo para entrenamiento y test)

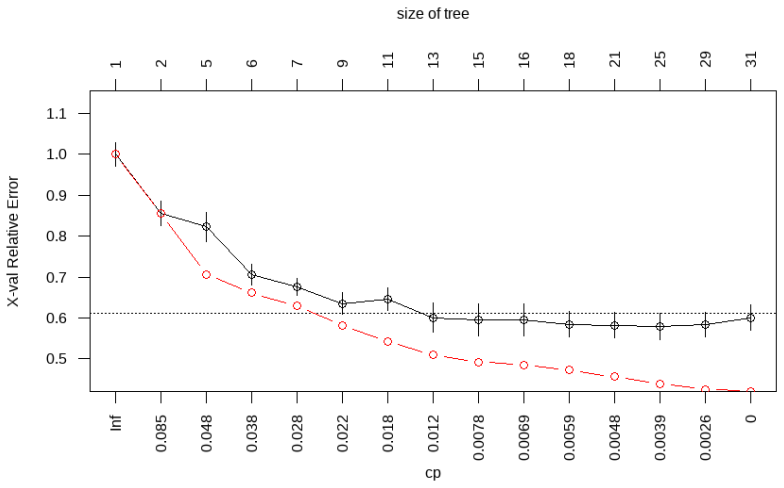

Figura 6 (tamaño del árbol frente a la mejora del índice kappa ponderado)

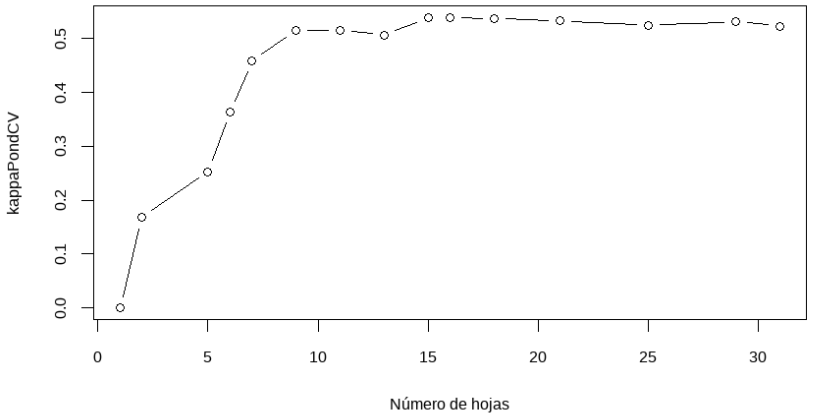

Figura 7 (árbol podado a 9 hojas con cp = 0.022)

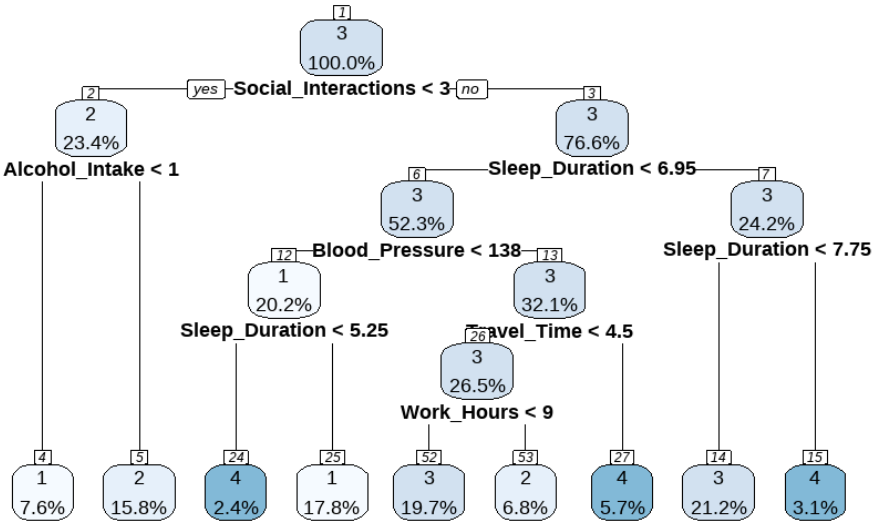

Figura 8 (credibilidad de las hojas del árbol podado *Figura 7*)

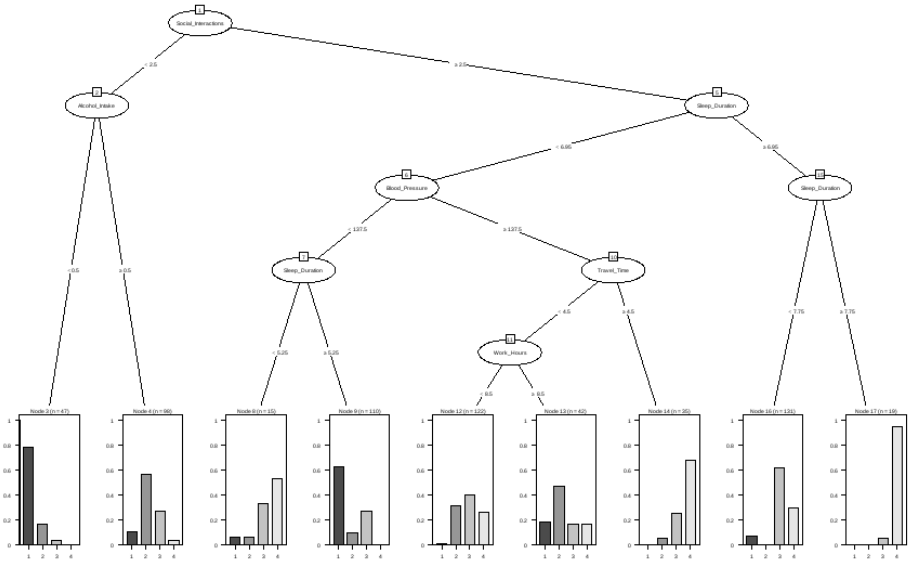

Figura 9 (importancia de las variables del árbol ganador)

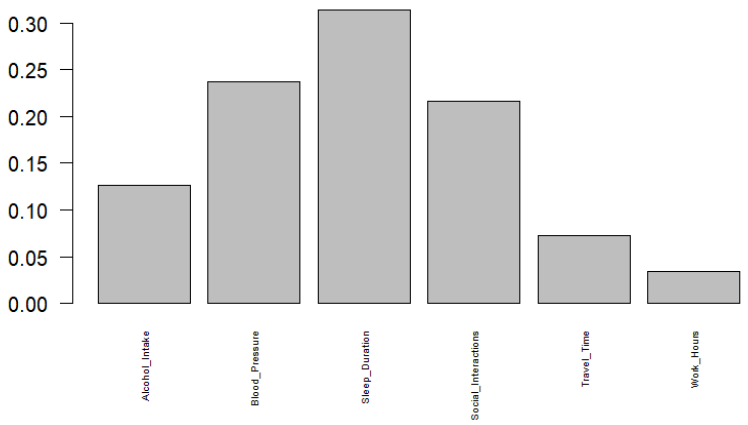

Figura 10 (comparación entre número de árboles para RF e índice kappa)

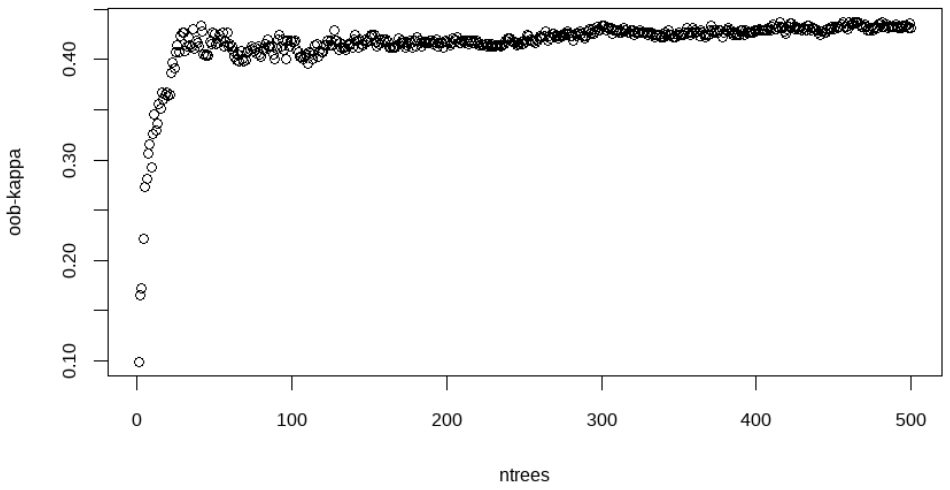

Figura 11 (comparación entre el tamaño de hoja y número de árboles necesarios para RF 5% → Rojo, 1% → Negro, 0.5% → Verde)

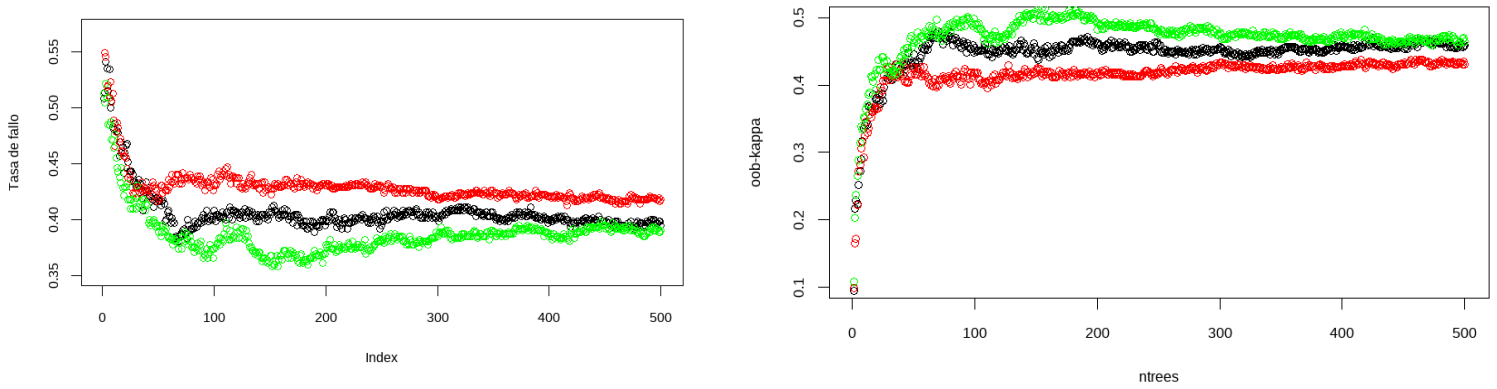

Figura 12 (valores mtry para RF de 150 árboles y tamaño de hoja al 0.5%)

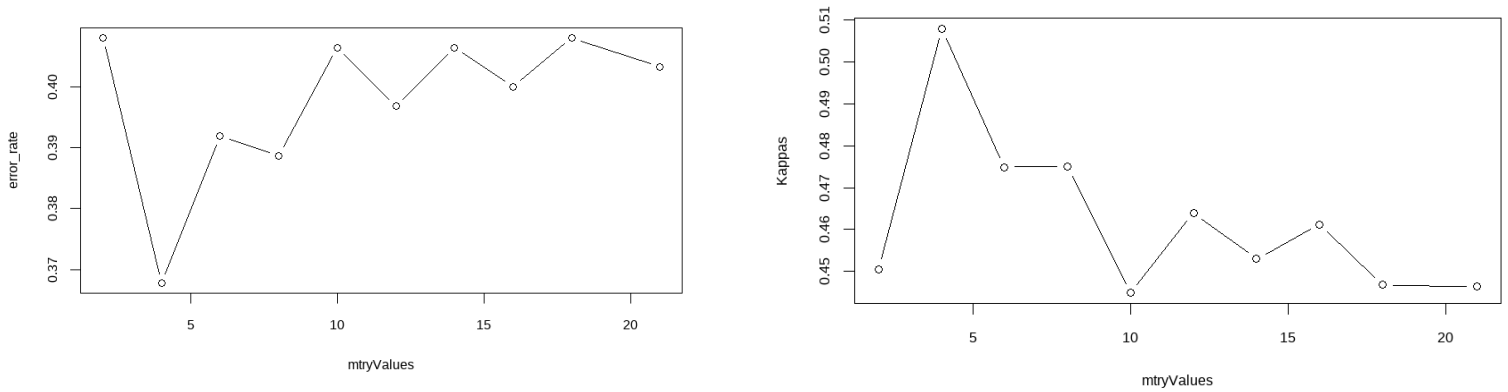

Figura 13 (importancia de las variables en RF ganador)

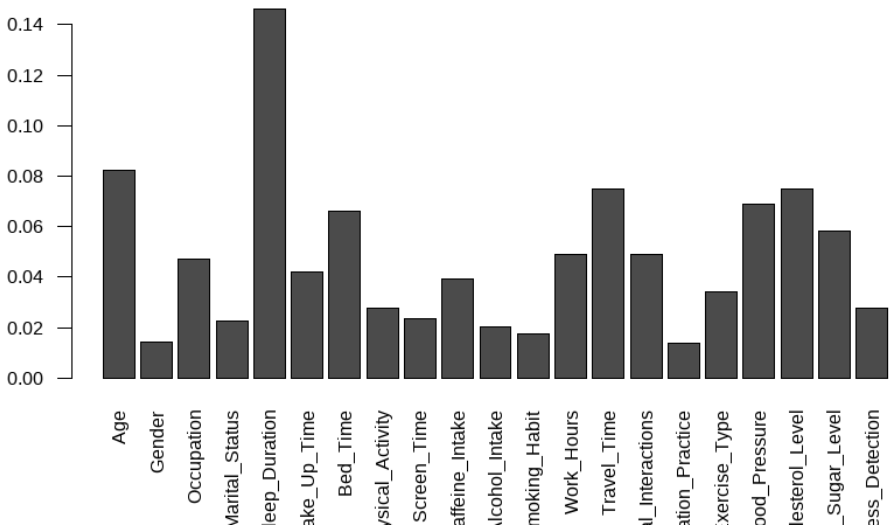

Figura 14 (distribución de las variable Sleep_Duration en función de la categoría)

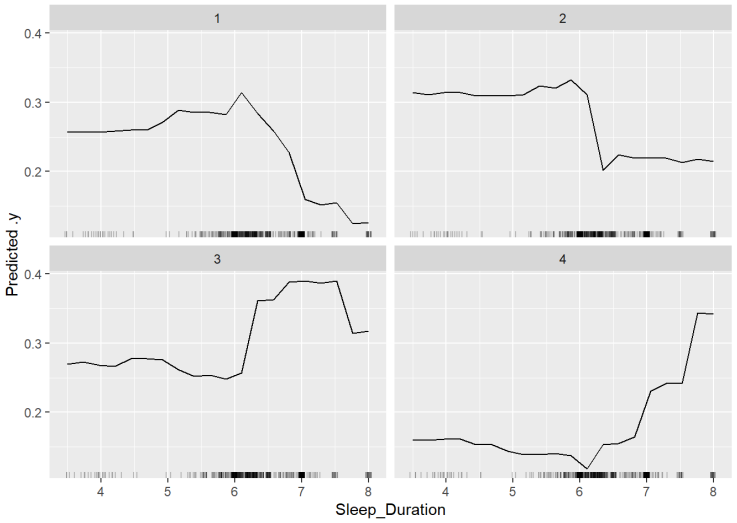

Figura 15 (evolución de deviance para determinar el número de árboles para entrenamiento y prueba)

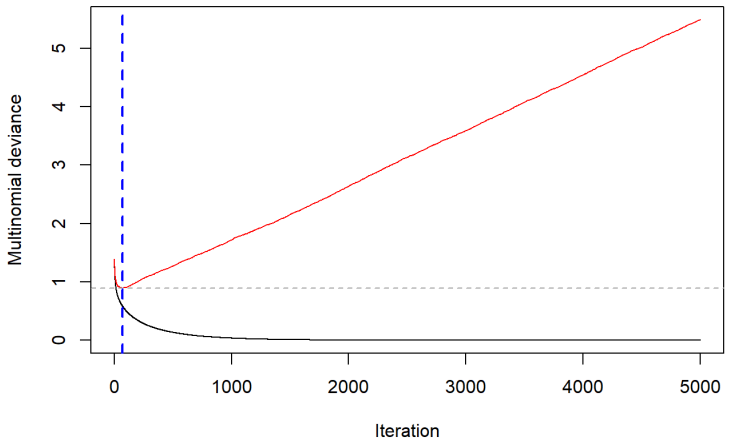

Figura 16 (comparación de los distintos GBM a partir de la rejilla de parámetros)

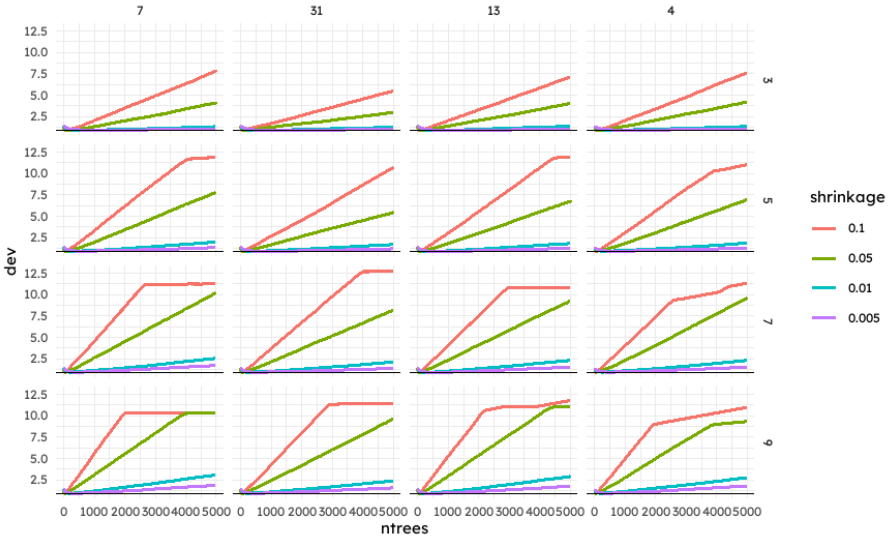

Figura 17 (gráfico para determinar número de árboles necesarios utilizando tasa de aprendizaje 0.05, profundidad 3 y obs mínimas por hoja de 31)

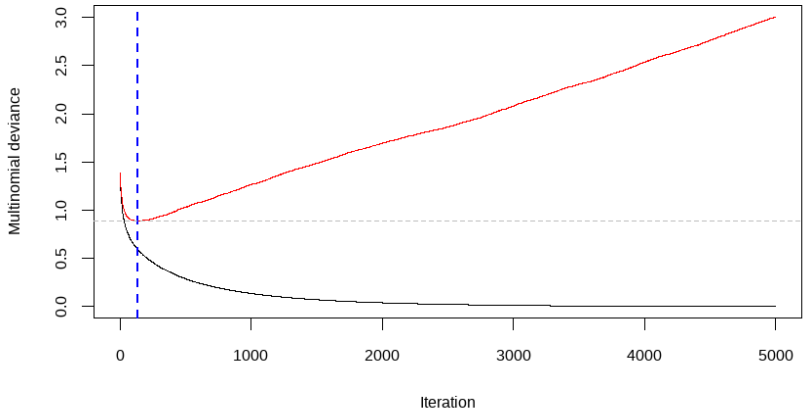
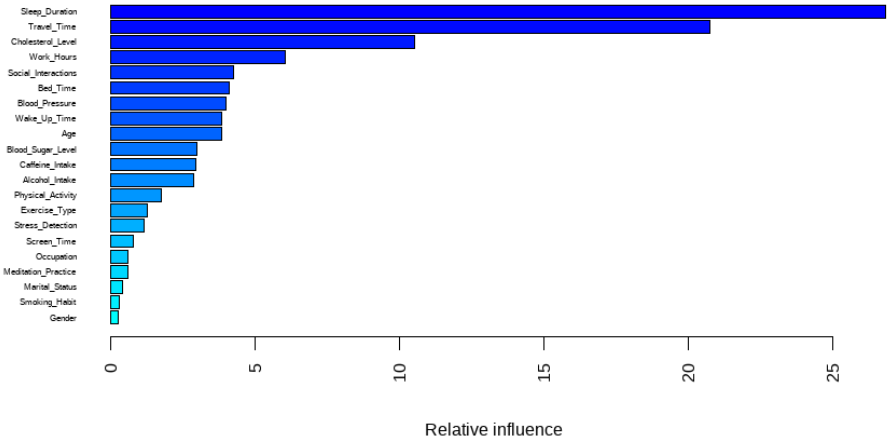
Figura 18 (importancia de las variables para el modelo GB ganador)